Questionário final: Medalhão, Storage, Qualidade e Governança

Instruções: responda com suas palavras e cite o que viu nos notebooks (nomes de tabelas, contagens, mensagens). Respostas sem exemplo concreto valem metade.

1. Object storage

1. O console do MinIO mostra "pastas" como `mercadonordeste/lote1`. Elas existem de verdade? Explique o que são e o que aconteceu no experimento de renomear.
2. Por que um object storage não consegue "editar uma linha" de um arquivo? O que ele faz no lugar?
3. Você parou o MinIO e o notebook deixou de funcionar, mas o pandas continuava instalado. O que isso diz sobre a separação entre armazenamento e processamento? Cite uma vantagem prática.
4. Landing e warehouse são buckets diferentes. Por que não guardar tudo no mesmo? Quem deveria poder gravar na landing? Quem deveria só ler a Bronze?

2. Bronze

5. Por que a Bronze **não** remove duplicados nem corrige tipos? O que se perderia se removesse?
6. Para que servem `_ingest_ts`, `_source_file` e `_batch_id`? Escolha um `pedido_id` e diga de qual arquivo e de qual lote ele veio.
7. Reexecutamos o mesmo lote e as linhas não dobraram. Como isso foi garantido? E o que aconteceu com o número de **objetos** no storage (na versão Iceberg e na versão pandas)? Por que são diferentes?
8. Uma tabela Iceberg tem as pastas `data/` e `metadata/`. O que cada uma guarda? Por que, na versão pandas, não existe `metadata/` e qual risco isso traz?

3. Silver

9. Cite três regras que a Silver aplicou e diga, para cada uma, o que acontece com o registro que a viola.
10. O que é a **quarentena** e por que ela é melhor que simplesmente apagar o registro inválido? Mostre um exemplo real do seu resultado.
11. Na Silver, o e-mail inválido virou `NULL` e a regra `not_null(email)` apareceu como `AVISO`, não `ERRO`. Por que essa escolha? Em que situação ela seria `ERRO`?
12. Deduplicamos os pedidos **antes** de explodir a coluna `itens`. O que aconteceria com o faturamento se fosse o contrário?
13. A conta "entrada = silver + quarentena" fechou? Se não fechasse, o que isso indicaria e o que você investigaria primeiro?
14. Os itens feitos "na mão" e os feitos pela função deram quantidades diferentes. Explique o motivo.

4. Gold

15. O que é o **grão** de uma tabela? Diga o grão de `vendas_diarias`, `clientes_360` e `avaliacoes_resumo`, e o que quebraria se o grão fosse violado.

16. Para que serve o contrato de dados (dono, grão, descrição das colunas)? Quem usa essas informações?
17. A Gold só é publicada se passar nos **gates**. Cite dois gates e explique por que bloquear a publicação é melhor do que apenas avisar.
18. Por que a receita da Gold foi recalculada "por outro caminho" e comparada com a Silver? Que tipo de erro essa checagem pega e uma checagem de nulos não pega?
19. A Gold foi copiada para o Postgres. Qual é a **fonte da verdade** e qual é a cópia? O que acontece se o Postgres for apagado?

5. Qualidade e observabilidade

20. Diferencie **limpar** dado de **medir** qualidade. Por que guardar o relatório do DQ em uma tabela?
21. Liste quatro sinais que você olharia, no dia a dia, para saber se o pipeline está saudável (por exemplo, contagens por camada, tamanho da quarentena, frescor, resultados do DQ). Para cada um, diga o que seria um sinal de alerta.
22. Cada execução do DQ gravou um objeto novo em vez de sobrescrever. Qual a vantagem disso para acompanhar a qualidade ao longo do tempo?

6. Versões, histórico e recuperação

23. Alguém apagou os pedidos cancelados por engano. Descreva como você descobriu o que mudou, voltou no tempo e desfez o erro (Iceberg e versionamento do bucket). Qual a diferença entre os dois?
24. Por que o dado antigo continuava existindo depois do `DELETE`? Qual o conflito disso com o direito ao esquecimento (LGPD) e o que resolveria?

7. Segurança, privacidade e segredos

25. Na `clientes_360` o nome está mascarado e o e-mail não existe. Que princípio de governança justifica isso? Que outro campo você proporia tratar?
26. Por que o Metabase deve usar um usuário **somente leitura**? Descreva o teste que prova que está certo.
27. As senhas deste laboratório (`admin12345`, `aula123`) aparecem no código. Por que isso é aceitável aqui e inaceitável em produção? Como isso seria feito em produção?
28. Por que a carga no Postgres usa `TRUNCATE` em vez de recriar a tabela? Cite o que quebraria no Metabase.

8. Visão de arquitetura

29. Desenhe (ou descreva) o fluxo completo, da landing ao Metabase, indicando em cada etapa: formato do dado, onde ele fica, e quem pode lê-lo.
30. Se o volume crescesse 1.000 vezes, o que você mudaria primeiro: a ferramenta de processamento, o catálogo (o Hadoop catalog não é indicado em S3 em produção) ou o formato? Justifique.

Pergunta aberta sobre IA: descreva um momento em que você usou uma IA para resolver um problema neste módulo. Que parte da resposta você confirmou rodando o código e que parte descartou? Como você sabe que ela estava certa?